

Тематическая структура лирики Ю. В. Жадовской в рукописном альбоме и прижизненных сборниках: машинный анализ корпуса

Итоговый проект по курсу «Компьютерная лингвистика»

Подготовила: Зеневич Екатерина Васильевна

Цель и задачи

Цель:

Исследовать тематическую структуру лирики Ю. В. Жадовской в рукописном альбоме и двух прижизненных сборниках с помощью методов машинного обучения и сравнить семантическую структуру трёх источников.

Задачи:

- Подготовить и провести разведочный анализ корпуса.
- Представить тексты с помощью TF-IDF и семантических эмбедингов.
- Выявить группы семантически близких произведений методами кластеризации и сравнить несколько алгоритмов.
- Сопоставить разные версии одних произведений в исследуемых источниках.
- Сравнить семантическую структуру альбома и двух сборников.
- Провести дополнительный эксперимент с нейросетевым сжатием семантических представлений.

Логика проекта



Предполагалось, что методы машинного обучения позволят автоматически обнаружить тематические группы произведений без заранее заданных тематических категорий.

Было сделано:

- проведены EDA и частотный анализ;
- тексты представлены через TF-IDF и семантические эмбединги;
- применены KMeans, Agglomerative Clustering и DBSCAN;
- сопоставлены версии произведений из разных источников;
- источники проанализированы вместе и по отдельности;
- дополнительно обучен автоэнкодер.



Анализ корпуса

	count	mean	median	min	max
source					
album	72	89.8	84.0	22	252
collection_1	58	81.8	72.5	29	252
collection_2	119	105.1	76.0	29	768




Сравнение silhouette score показывает, что семантические эмбединги на всём рассмотренном диапазоне k дают более высокие значения, чем TF-IDF.

Максимальное значение получено
при $k = 18$: 0.0643 для TF-IDF
и 0.1045 для семантических эмбедингов.



Распределение 18 кластеров по слоям первого появления произведений (в альбоме, первом и втором сборниках).

Числа показывают долю каждого кластера в соответствующем слое в процентах. Видно, что распределение меняется: например, кластер 2 очень выделяется в первом сборнике (24%), кластер 12 — в альбоме (18,1%), а кластер 16 — во втором сборнике (25%). Это показывает, что автоматически выделенные семантические группы представлены в источниках неодинаково.





Сравнение методов кластеризации

Три метода кластеризации дали разные результаты.

1. KMeans при $k=18$ показал silhouette score 0,1045. Полученные кластеры оказались достаточно подробными для дальнейшего анализа.
2. При Agglomerative Clustering silhouette score увеличивался при росте числа кластеров и достиг 0,1366 при $k=30$. Однако такое разбиение сильнее дробит небольшой корпус на отдельные группы.
3. DBSCAN оказался чувствителен к параметру eps. При малых значениях большая часть текстов определялась как шум, а при больших практически весь корпус объединялся в один кластер. При $\text{eps}=0.25$ были получены 3 кластера и 21 шумовой текст.

	Метод	Параметры	Результат	Silhouette
0	KMeans	$k=18$	18 кластеров	0.1045
1	Agglomerative Clustering	$k=30$	30 кластеров	0.1366
2	DBSCAN	$\text{eps}=0.25, \text{min_samples}=3$	3 кластера, 21 текст — шум	0.1316


Визуализация семантического пространства



Подбор количества кластеров для каждого источника

source_cluster	0.0	1.0
source		
album	20	52
collection_1	16	42
collection_2	56	63

Соотношение семантических противопоставлений в трёх источниках




Результат нейросетевого эксперимента

Автоэнкодер был обучен на семантических эмбедингах 249 текстов. Исходное представление размерности 384 было сжато до 32 признаков без использования тематических меток.

После обучения полученные представления были кластеризованы методом KMeans. Максимальное значение silhouette score в диапазоне от 2 до 20 кластеров составило 0,1249 при $k=19$. Для исходных семантических эмбедингов максимальное значение в том же диапазоне составляло 0,1045 при $k=18$.

Таким образом, нейросетевое сжатие немного улучшило разделение текстов в пространстве признаков, но значение silhouette score остаётся невысоким. Это согласуется с предыдущими экспериментами и даёт основание сделать вывод, что тематическая структура корпуса имеет размытые границы и не сводится к набору полностью обособленных групп.



Результаты

Получилось:

В общем корпусе обнаружены отдельные интерпретируемые тематические ядра, однако чёткой системы изолированных тематических групп не возникло. При отдельной кластеризации источников устойчиво проявилось более крупное противопоставление двух семантических противопоставлений — условно «внешнего мира» и «внутреннего мира». В альбоме и первом сборнике их соотношение оказалось практически одинаковым, тогда как во втором сборнике доля «внешнего» полюса заметно выше.

Не получилось:

Автоматически разделить весь корпус на несколько чётких и однозначно интерпретируемых тем. Невысокие значения silhouette score и визуализации показали, что границы между семантическими группами размыты.

Дополнительный результат:

Обученный автоэнкодер сжал семантические представления с 384 до 32 признаков; после этого максимальный silhouette score KMeans незначительно вырос — с 0,1045 до 0,1249.